

Analyse FMDS et Maintenance Prédicative d'un Turbofan

Estimation du Remaining Useful Life (RUL) à partir du jeu de données NASA C-MAPSS

Youssef Smei
3ème GMAM ENSIT

16 novembre 2025

Table des matières

1	Introduction et contexte industriel	3
2	Objectifs du projet et problématique	3
2.1	Objectif général	3
2.2	Objectifs spécifiques	4
2.3	Problématique	4
3	Présentation du système étudié	4
3.1	Description fonctionnelle du turbofan	4
3.2	Capteurs et paramètres de fonctionnement	4
4	Données utilisées et prétraitements	5
4.1	Description du jeu de données	5
4.2	Construction de la variable RUL	5
4.3	Inspection et qualité des données	5
4.4	Analyse exploratoire des capteurs	6
4.5	Sélection de caractéristiques et normalisation	7
4.6	Ajout d'historique (rolling mean)	7
5	Analyse FMDS (indicateurs, interprétation)	7
5.1	Rappels sur les indicateurs FMDS	7
5.2	Interprétation FMDS des résultats	8
6	Diagnostic et pronostic (méthodes, résultats)	8
6.1	Formulation du problème de régression (pronostic RUL)	8
6.2	Résumé des résultats de régression	9
6.3	Formulation du problème en classification (diagnostic sur classes de RUL)	9

7	Validation des modèles (métriques et discussion)	10
7.1	Métriques utilisées	10
7.2	Validation croisée	10
7.3	Overfitting des modèles d'ensembles	10
7.4	Importance des caractéristiques	11
8	Synthèse, recommandations et perspectives	11
8.1	Synthèse des principaux résultats	11
8.2	Recommandations pour une mise en œuvre industrielle	11
8.3	Perspectives	12

1 Introduction et contexte industriel

Les systèmes aéronautiques modernes, et en particulier les moteurs turbofan, sont soumis à des conditions de fonctionnement sévères (variations de température, de pression, de charge, etc.) qui entraînent une dégradation progressive des composants critiques. Cette dégradation impacte directement la fiabilité, la disponibilité et les coûts d'exploitation de la flotte.

Dans ce contexte, la **maintenance prédictive** et l'analyse **FMDS** (Fiabilité, Maintenabilité, Disponibilité, Sécurité) jouent un rôle central pour :

- détecter précocement les modes de défaillance,
- estimer la durée de vie résiduelle (*Remaining Useful Life – RUL*),
- planifier les interventions de maintenance au moment optimal,
- améliorer la sécurité et réduire les temps d'arrêt non planifiés.

Le présent travail s'inscrit dans le cadre d'un projet pratique d'analyse FMDS et de maintenance prédictive, conformément au guide pédagogique fourni. Il s'appuie sur le jeu de données public **NASA C-MAPSS**, qui contient des mesures simulées de moteurs turbofan en fonctionnement jusqu'à défaillance.

L'objectif principal est de développer, évaluer et comparer plusieurs modèles d'apprentissage automatique (régression et classification) pour prédire le RUL des moteurs, tout en reliant cette démarche aux concepts FMDS.

2 Objectifs du projet et problématique

2.1 Objectif général

L'objectif général du projet est de concevoir une chaîne complète de maintenance prédictive permettant d'estimer le RUL d'un moteur turbofan à partir de signaux capteurs multivariés, puis de discuter l'apport de cette estimation dans une démarche FMDS.




FIGURE 1 – Schéma d'un moteur turbofan et ses différentes composantes.

2.2 Objectifs spécifiques

Plus précisément, le projet vise à :

- **Comprendre et analyser** le jeu de données NASA C-MAPSS (sous-ensemble FD001) : structure, capteurs, évolutions temporelles.
- **Construire la variable cible RUL** et réaliser une ingénierie de caractéristiques (features statistiques et historiques).
- **Mettre en œuvre plusieurs modèles de régression** (régression linéaire, SVR, Random Forest, XGBoost, etc.) pour la prédiction du RUL.
- **Étudier une formulation en classification** en binant les valeurs de RUL en classes (RUL faible, moyen, élevé) et en comparant différentes méthodes (SVC, Random Forest Classifier, Naïve Bayes, KNN).
- **Évaluer les performances** des modèles via des métriques adaptées (RMSE, R^2 , exactitude, matrices de confusion) et **discuter les risques d'overfitting**.
- **Relier les résultats aux indicateurs FMDS** et discuter les implications pour la prise de décision en maintenance.

2.3 Problématique

La problématique peut être formulée de la manière suivante :

À partir de mesures capteurs d'un moteur turbofan en fonctionnement, comment estimer de manière fiable sa durée de vie résiduelle (RUL) afin d'anticiper les défaillances critiques, tout en tenant compte des contraintes de fiabilité, de disponibilité et de sécurité du système ?

3 Présentation du système étudié

3.1 Description fonctionnelle du turbofan

Le moteur turbofan étudié est composé de plusieurs sous-systèmes majeurs :

- **Compresseur basse pression (LPC)** et **compresseur haute pression (HPC)**, qui élèvent la pression de l'air.
- **Chambre de combustion**, où le carburant est injecté et brûlé.
- **Turbines (LPT/HPT)** qui récupèrent l'énergie des gaz chauds pour faire tourner les compresseurs et le fan.
- **Rotors basse et haute pression (N1, N2)**, liés à la vitesse physique du fan et du cœur.
- **Systèmes de refroidissement et de contrôle** (débits d'air de refroidissement, rapports carburant/air).

Le sous-ensemble FD001 du jeu NASA C-MAPSS correspond à un scénario de défaillance de type **HPC failure** (dégradation du compresseur haute pression). Chaque moteur est considéré en bon état au début de la série temporelle, puis se dégrade progressivement jusqu'à la panne.

3.2 Capteurs et paramètres de fonctionnement

Le dataset fournit pour chaque cycle de fonctionnement :

- un **identifiant d'unité** (`unit_number`) et un **indice de cycle** (`time_cycles`),

- trois **paramètres de réglage** (`setting_1`, `setting_2`, `setting_3`),
- vingt et un **capteurs** (`s_1` à `s_21`), liés à des grandeurs physiques telles que :
 - températures (entrée fan, sortie LPC, HPC, LPT),
 - pressions (HPC outlet, bypass, etc.),
 - vitesses physiques et corrigées (fan, core),
 - rapports de pression et de débit carburant/air,
 - débits d'air de refroidissement des turbines.

Ces capteurs permettent de suivre l'état de santé du moteur au fil des cycles.

4 Données utilisées et prétraitements

4.1 Description du jeu de données

Le sous-ensemble FD001 du jeu C-MAPSS contient :

- **100 moteurs** (unités),
- **20631 observations** dans l'ensemble d'entraînement,
- **13096 observations** dans l'ensemble de validation,
- **26 colonnes** : identifiant, cycle, 3 réglages, 21 capteurs.

	Entraînement	Validation
Nombre de lignes	20631	13096
Nombre d'unités	100	100
Nombre de capteurs	21	21

TABLE 1 – Résumé des dimensions du jeu de données FD001

4.2 Construction de la variable RUL

Pour chaque moteur, le RUL est défini comme le nombre de cycles restant avant la défaillance. La procédure appliquée est la suivante :

1. Pour chaque `unit_number`, on calcule le cycle maximal `max_time_cycle`.
2. Pour chaque observation, on définit

$$\text{RUL} = \text{max_time_cycle} - \text{time_cycles}.$$

Cette opération donne une variable RUL décroissante au cours du temps, allant d'une valeur initiale (parfois supérieure à 300 cycles) jusqu'à zéro au moment de la panne.

4.3 Inspection et qualité des données

Les vérifications suivantes ont été effectuées :

- **Valeurs manquantes** : aucun NaN n'a été détecté dans les capteurs ni dans les réglages.
- **Statistiques descriptives** des cycles : les moteurs cassent entre environ 128 et 362 cycles, avec une moyenne autour de 200 cycles.




FIGURE 2 – Distribution du nombre maximal de cycles par moteur

4.4 Analyse exploratoire des capteurs

Une matrice de corrélation a été calculée entre toutes les variables, incluant la RUL. Certains capteurs présentent une corrélation notable avec la RUL (par exemple s_3 , s_4 , s_7 , s_9 , s_{11} , s_{12}), tandis que d'autres sont constants ou quasi constants.




FIGURE 3 – Matrice de corrélation entre capteurs, réglages et RUL

Des visualisations de l'évolution des capteurs en fonction de la RUL ont également

été réalisées, en traçant les courbes pour un sous-ensemble de moteurs. On observe par exemple que :

- la vitesse du cœur (**s_9**) et certaines pressions (**s_7**, **s_11**) augmentent ou se dégradent de manière monotone à l’approche de la panne,
- certains capteurs (**s_1**, **s_5**, **s_10**, **s_16**, **s_18**, **s_19**) sont constants sur tout l’historique.

4.5 Sélection de caractéristiques et normalisation

Sur la base des analyses précédentes :

- Les capteurs **constants** (**s_1**, **s_5**, **s_6**, **s_10**, **s_16**, **s_18**, **s_19**) ont été **supprimés**.
- Les variables d’index (**unit_number**, **time_cycles**) et les réglages **setting_1-3** ont été utilisées pour construire le RUL mais non fournies directement aux modèles.
- Un **MinMaxScaler** a été appliqué sur les capteurs retenus pour les ramener dans l’intervalle $[0, 1]$, afin d’améliorer la stabilité numérique et la convergence des modèles.

4.6 Ajout d’historique (rolling mean)

Pour capturer la dimension temporelle sans passer à un modèle séquentiel complexe, des **caractéristiques historiques** ont été construites :

- pour chaque capteur conservé, une moyenne glissante sur 10 cycles (*rolling mean*) a été calculée,
- ces nouvelles variables (**s_k_rm**) enrichissent l’information sur la tendance locale du capteur.

5 Analyse FMDS (indicateurs, interprétation)

Même si le jeu de données NASA C-MAPSS ne fournit pas directement des historiques de pannes/réparations permettant de calculer des indices FMDS complets (MTBF, MTTR, taux de réparation, etc.), il est possible de **relier les résultats de RUL à la logique FMDS**.

5.1 Rappels sur les indicateurs FMDS

- **Fiabilité** : probabilité que le système accomplisse sa fonction sans panne pendant un intervalle de temps donné. Les indicateurs classiques sont le *Mean Time Between Failures* (MTBF) et la fonction de survie.
- **Maintenabilité** : aptitude du système à être réparé rapidement après une panne (indice MTTR, distributions des temps de réparation).
- **Disponibilité** : proportion de temps pendant laquelle le système est opérationnel, typiquement $A = \frac{MTBF}{MTBF+MTTR}$.
- **Sécurité** : capacité à éviter des défaillances critiques pouvant mettre en jeu la sûreté de fonctionnement ou la sécurité des personnes.

Dans ce projet, la prédiction du RUL permet surtout d’agir sur :

- la **fiabilité perçue** (en évitant les pannes en vol),
- la **disponibilité** (meilleure planification des arrêts de maintenance),

- la **sécurité** (éviter de fonctionner à RUL très faible).

5.2 Interprétation FMDS des résultats

On observe que :

- Les modèles de régression permettent d'estimer le RUL avec une erreur moyenne (RMSE) de l'ordre de 30 à 35 cycles sur le meilleur compromis.
- La classification en classes de RUL permet d'identifier les situations de « RUL faible » avec une exactitude globale d'environ 66 % (trois classes équilibrées).

Dans une logique FMDS, ces performances peuvent :

- réduire les **pannes inopinées** (en déclenchant une maintenance dès que la classe « RUL faible » est détectée),
- améliorer la **planification des arrêts** (en tenant compte de la distribution des RUL estimés sur la flotte),
- alimenter un **tableau de bord FMDS** en complément d'autres indicateurs (taux de panne, durée d'indisponibilité, etc.).

6 Diagnostic et pronostic (méthodes, résultats)

6.1 Formulation du problème de régression (pronostic RUL)

La première étape consiste à formuler le problème comme une **régression supervisée** :

- **Entrées** : vecteur de capteurs (bruts puis enrichis par rolling mean),
- **Sortie** : valeur scalaire du RUL (nombre de cycles restants).

Trois tentatives principales ont été mises en place :

1. **Tentative 1** : toutes les caractéristiques, sans historique.
2. **Tentative 2** : suppression des capteurs constants, RUL *clippé* à 195 cycles.
3. **Tentative 3** : suppression des capteurs constants + ajout des moyennes glissantes.

Les modèles évalués sont :

- Régression linéaire implémentée manuellement,
- SVR (*Support Vector Regression*, noyau RBF),
- Random Forest Regressor,
- XGBoost Regressor.

6.2 Résumé des résultats de régression

Tentative	Modèle	RMSE train	RMSE test	RMSE valid
1	Régr. linéaire	≈ 56	≈ 54	≈ 35
1	SVR	≈ 44	≈ 47	≈ 35
1	Random Forest	≈ 15	≈ 44	≈ 31
2	Régr. linéaire	≈ 48	≈ 56	≈ 34
2	SVR	≈ 33	≈ 49	≈ 26
2	Random Forest	≈ 12	≈ 46	≈ 27
2	XGBoost	≈ 36	≈ 50	≈ 26
3	Régr. linéaire	≈ 41	≈ 40	≈ 38
3	SVR	≈ 32	≈ 34	≈ 27
3	Random Forest (de base)	≈ 10	≈ 30	≈ 37
3	Random Forest (tuning)	≈ 24	≈ 30	≈ 39
3	XGBoost (tuning)	≈ 24	≈ 31	≈ 36

TABLE 2 – Performances des principaux modèles de régression (RMSE, R^2)

On constate que :

- Les Random Forest et XGBoost atteignent des erreurs très faibles sur l'entraînement mais dégradent sur la validation (**overfitting**).
- Le **SVR** offre le **meilleur compromis** entre biais et variance, avec un RMSE test autour de 33–34 cycles et une performance valide raisonnable (environ 27 cycles d'erreur).
- L'ajout de l'**historique (rolling mean)** améliore nettement la généralisation par rapport aux tentatives 1 et 2.

6.3 Formulation du problème en classification (diagnostic sur classes de RUL)

Pour mieux distinguer les situations critiques, le problème a été reformulé en **classification multiclasse** :

- RUL élevé (classe 1),
- RUL moyen (classe 2),
- RUL faible (classe 3).

Les bornes des classes ont été choisies de façon à obtenir des classes relativement équilibrées (histogrammes de RUL).

Les modèles testés incluent :

- SVC (Support Vector Classifier),
- Random Forest Classifier,
- Naïve Bayes,
- KNN.

L'évaluation finale montre une **exactitude globale** d'environ **66 %**, avec des rappels par classe de l'ordre de 0.46 à 0.89 selon la classe et le modèle.

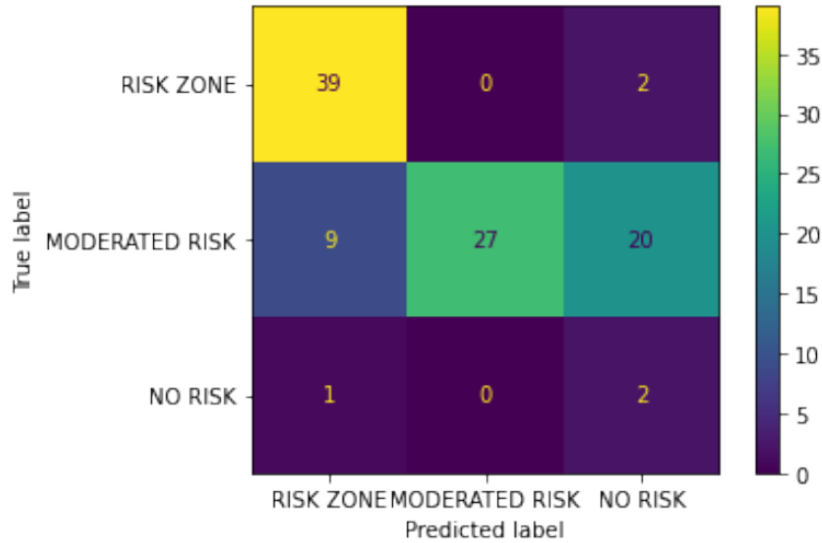


FIGURE 4 – Exemple de matrice de confusion pour la classification en 3 classes de RUL.

Cette approche est intéressante pour un **diagnostic qualitatif** (sain / dégradé / proche de la panne) mais reste moins précise que la régression pour la planification fine des interventions.

7 Validation des modèles (métriques et discussion)

7.1 Métriques utilisées

Pour la régression :

- **MSE** : Mean Squared Error,
- **RMSE** : Root Mean Squared Error,
- R^2 : coefficient de détermination.

Pour la classification :

- **Exactitude** (accuracy),
- **Précision, rappel, F1-score** par classe,
- **Matrice de confusion**.

7.2 Validation croisée

Une validation croisée **K-fold** (**K=4**) a été réalisée sur le meilleur pipeline (SVR avec données enrichies par moyennes glissantes) :

- RMSE train ≈ 32.5 ,
- RMSE test entre 32.5 et 33.0,
- RMSE valid autour de 27.5–28.0.

Ces résultats montrent une **bonne stabilité** du modèle SVR et une capacité raisonnable de généralisation sur des moteurs non vus.

7.3 Overfitting des modèles d'ensembles

Les modèles Random Forest et XGBoost présentent :

- des **erreurs très faibles** sur les données d’entraînement ($\text{RMSE} \approx 10\text{--}25$),
- des **erreurs significativement plus élevées** sur validation ($\text{RMSE} \approx 36\text{--}39$).

Malgré l’utilisation de :

- profondeur maximale limitée (`max_depth`),
- nombre d’arbres modéré (`n_estimators`),
- régularisation (XGBoost, `reg_lambda`, `gamma`),

les modèles restent plus sensibles au sur-apprentissage que le SVR sur ce dataset.

7.4 Importance des caractéristiques

Les analyses d’importance de variables (Random Forest, XGBoost, régression linéaire) montrent que :

- les capteurs `s_9`, `s_11`, `s_12`, `s_7`, et leurs versions lissées (`s_9_rm`, etc.) contribuent fortement à la prédiction du RUL,
- certaines caractéristiques dérivées (rolling mean) jouent un rôle similaire voire plus important que les signaux bruts.

8 Synthèse, recommandations et perspectives

8.1 Synthèse des principaux résultats

- Une chaîne complète de maintenance prédictive a été mise en place sur le jeu NASA C-MAPSS (FD001), depuis l’ingénierie de la RUL jusqu’à l’évaluation des modèles.
- L’ajout d’**historique** via des moyennes glissantes de capteurs améliore la performance globale des modèles.
- Le **SVR** apparaît comme le **meilleur compromis** régression/biais-variance, avec un $\text{RMSE}_{\text{test}} \approx 33$ et une bonne stabilité en validation croisée.
- Les modèles d’ensemble (Random Forest, XGBoost) obtenant des RMSE très faibles sur le train sont toutefois victimes d’**overfitting**, en particulier sur le jeu de validation.
- La **classification en classes de RUL** permet d’obtenir une exactitude globale d’environ 66 %, utile pour un diagnostic qualitatif (*état de santé global*) mais moins précis pour la planification fine.

8.2 Recommandations pour une mise en œuvre industrielle

- Intégrer le modèle de prédiction de RUL dans un **tableau de bord FMDS** pour relier directement les estimations de durée de vie aux indicateurs de disponibilité et de fiabilité.
- Coupler la prédiction de RUL à une **politique de maintenance optimisée** (par exemple basée sur des seuils de RUL et des contraintes de capacité des ateliers).
- Enrichir les données avec de **vraies informations de pannes et de temps de réparation** pour calculer MTBF, MTTR et disponibilité réelle.
- Étendre l’approche à d’autres sous-ensembles C-MAPSS (FD002–FD004) pour tester la robustesse du pipeline sur des scénarios de défaillance plus complexes.

8.3 Perspectives

Plusieurs pistes d'amélioration sont envisageables :

- Mise en œuvre de modèles séquentiels avancés (LSTM, GRU, Transformers) pour exploiter directement la structure temporelle des séries.
- Utilisation de méthodes de **fiabilité statistique** (Weibull, loi exponentielle, modèles de survie) pour coupler explicitement FMDS et prédiction de RUL.
- Étude de **stratégies de maintenance conditionnelle** basées sur des scénarios de coûts et de risques.

Bibliographie

- Jardine, A. K. S., Lin, D., & Banjevic, D. (2006). *A review on machinery diagnostics and prognostics*. Mechanical Systems and Signal Processing.
- Heng, A. et al. (2019). *Condition-based maintenance using machine learning*. Reliability Engineering & System Safety.
- Documentation NASA C-MAPSS et ressources PHM Society.